

De Datos a Destinos: Un Enfoque de Machine Learning para Estimar el Turismo Extranjero en Colombia

Pablo Alejandro Reyes Granados

Universidad Externado de Colombia

pablo.reyes4@est.uexternado.edu.co

Resumen

En el contexto de la predicción de flujos turísticos, los métodos econométricos tradicionales han mostrado limitaciones para capturar dinámicas complejas y variables interrelacionadas en datos panel. En esta investigación, se evaluaron diversas técnicas de machine learning para predecir el número de turistas extranjeros mensuales en las 81 principales ciudades de Colombia, identificándose a XGBoost como el modelo con mejor desempeño. Además, no solo se quedó con un modelo “caja negra”, sino que se aplicó un análisis LIME para interpretar la influencia de las variables. Los resultados no solo evidencian una mejora significativa en la precisión predictiva respecto a las técnicas econométricas clásicas, sino que también proporcionan una visión más detallada de los factores determinantes del flujo turístico. Este estudio destaca el potencial de los enfoques basados en machine learning para optimizar la toma de decisiones en el sector turístico y aportar una nueva herramienta para planificar estrategias por parte de las ciudades colombianas.

1. Introducción

Es innegable que el turismo extranjero es un motor económico para todas las ciudades colombianas. Concretamente, según el Ministerio de Comercio, Industria y Turismo, en ciudades principales como Bogotá o Medellín, el turismo representa del 3 al 4.5 por ciento del PIB y se han llegado a cifras máximas del 10 por ciento; mientras que, en ciudades con distritos netamente turísticos como Cartagena o Santa Marta, la participación del turismo en el PIB no baja del 7 por ciento. Es por esto que, naturalmente, surge la necesidad de que los economistas traten de estimar los factores que permiten a las ciudades atraer un flujo turístico significativo o, en su defecto, lograr una estimación estadísticamente representativa del futuro turístico de las ciudades.

Tradicionalmente, se han aplicado métodos econométricos clásicos, como las regresiones lineales, para desentrañar estos patrones y formular conclusiones sobre el fenómeno turístico. Aunque en teoría estos modelos pueden resultar adecuados, en la práctica los datos relacionados con el turismo a menudo exhiben comportamientos no lineales y complejos. Este escenario plantea un reto para las técnicas econométricas, pues no logran capturar de manera eficaz la complejidad inherente a la dinámica turística. En este contexto, el machine learning (ML) surge como una aproximación prometedora y robusta para abordar el problema de la predicción del turismo. Algoritmos avanzados, entre los que destacan los métodos de boosting, permiten modelar relaciones no lineales y detectar patrones sutiles en los datos que las metodologías convencionales podrían pasar por alto.

Esta investigación se centra en evaluar y comparar diferentes modelos de machine learning, demostrando que, más allá de lograr una mayor precisión en la predicción del número de turistas extranjeros, estos nuevos enfoques permiten superar las limitaciones de los métodos econométricos clásicos, ofreciendo herramientas más eficaces y precisas para la toma de decisiones en el ámbito del turismo.

2. Aproximación al Problema y Metodología

En esta sección se describe la aproximación adoptada para abordar el análisis del flujo de turistas extranjeros. Se especifican las fuentes de datos y el proceso de recolección utilizado. Se define detalladamente la variable dependiente y las variables independientes. Se explica cómo se construyeron las variables más significativas y se realizó su preprocesamiento. Todo ello sienta las bases metodológicas para el posterior modelado del fenómeno turístico.

2.1. Recolección De los Datos

Esta es, sin duda alguna, la parte más importante de toda investigación enfocada en Machine Learning, puesto que la capacidad de predicción de un modelo depende en gran medida de la calidad de los datos empleados.

Con el fin de identificar variables capaces de predecir el turismo extranjero en Colombia, se construyó un conjunto de datos de tipo panel, en donde cada observación representa una ciudad en un mes, en el periodo de tiempo desde 2018 hasta 2023, exceptuando el año 2020, debido a las alteraciones significativas en la dinámica turística ocasionadas por la pandemia. La selección de las ciudades se realizó en función del tamaño poblacional, optando por aquellas con un mínimo de 20 mil habitantes, lo que resultó en un total de 81 ciudades a lo largo del país. Esta metodología garantiza una muestra representativa, facilitando un análisis robusto de los factores que influyen en el flujo turístico.

2.1.1. Variable Dependiente

Considerando que nuestro modelo es de tipo regresión, la variable dependiente corresponde al destino final de todos los visitantes no residentes que llegan a Colombia por los diferentes puntos migratorios. Esta información es publicada por el Ministerio de Industria, Comercio y Turismo mensualmente. Esta variable es continua y se expresa en números absolutos de turistas por ciudad, lo cual permite comprender la magnitud de los flujos y facilita la realización de comparaciones temporales.




Figura 1: Scores de las variables y número de extranjeros. Elaboración Propia

Como se puede ver en la figura 1, el año en el que se recibió mayor cantidad de turistas fue 2023 y el de menor afluencia, 2021, debido a los rezagos de la pandemia. Los picos de turismo se registran en junio, julio y diciembre.

Por otro lado, el promedio mensual en la serie de tiempo es de 231 mil visitantes extranjeros. En la figura de la derecha se observa que la mayoría de estos visitantes acuden a Bogotá (42,8 por ciento), seguida de Cartagena y Medellín; en general, se evidencia que el grueso del turismo se concentra en solo tres ciudades, dejando a las 78 restantes con únicamente el 20 por ciento de los visitantes.

2.1.2. Variables Independientes

Una de las mayores limitaciones de la econometría clásica es la cantidad de supuestos que se requieren para que las estimaciones del modelo sean válidas. En particular, establecer una forma funcional clara que capture las complejas relaciones entre las variables es un desafío considerable, ya que en muchos casos las interacciones en el mundo real no son lineales, polinomiales o multifacéticas. Esta primera necesidad, representa una gran restricción al análisis del turismo desde un enfoque clásico de econometría, pues muchas de las variables en este campo no se ajustan a una especificación sencilla. Por otro lado, la multicolinealidad impide trabajar con variables que muestran un alto grado de correlación entre sí, lo que representa otro gran problema, ya que se deben omitir variables que se esperaría que tengan un efecto significativo de forma combinada, solo por estar correlacionadas.

En contraste, al pasar al paradigma del Machine Learning, no se imponen supuestos preestablecidos sobre la forma funcional de las relaciones entre variables; es el propio modelo el que descubre la estructura subyacente a partir de los datos. Esto libera al investigador de tener que definir de antemano

cómo se relacionan las variables, permitiendo que incluso los modelos más básicos identifiquen patrones no lineales y complejos de manera autónoma.

Teniendo esto claro podemos empezar a describir cuales son y como se construyeron las variables que se usaron en el modelo. Para esta investigación se crearon más de 31 variables independientes. Dada la gran cantidad de variables, se optó por clasificarlas en grupos temáticos amplios, lo que facilita su análisis.

1. **Variables Espaciales:** En esta temática encontramos todas las variables que incorporan un componente geográfico. Entre ellas se incluyen: la distancia ponderada de cada ciudad a los diferentes puntos de acceso internacional del país, la distancia ponderada a los principales puntos turísticos, el área urbana, el área rural de cada ciudad y el número de vías principales cercanas.
2. **Variables Económicas:** Aquí se incluyen las variables económicas que se consideraron más significativas para la predicción, tales como: el precio del dólar, el PIB ponderado por ciudad, un proxy de pobreza de cada ciudad y la inflación.
3. **Variables de seguridad:** Dado que la percepción de seguridad es fundamental al elegir un destino turístico, se incluyeron indicadores de criminalidad. Específicamente: el número de homicidios, hurtos y delitos sexuales de cada ciudad en cada mes.
4. **Variables de Infraestructura Turística** En esta sección se agrupan variables que reflejan la capacidad y oferta turística de cada ciudad, como: el número de establecimientos de turismo de cada ciudad, el número de habitaciones, el número de camas y el número de eventos representativos que ocurren en cada mes en las ciudades.
5. **Variables Climáticas** El clima es otro factor significativo al momento de escoger un destino turístico, por lo que incluimos la temperatura promedio de las ciudades y el área de agua que tiene cada una de ellas.
6. **Variables de gastos turísticos** Se analizaron variables que capturan el comportamiento del gasto por viaje en cada ciudad, en base a variables como: Gasto Promedio Viaje, Gasto Alojamiento Viaje, Gasto Transporte Viaje, Gasto Alimentos Viaje y Otros Gastos.

2.2. Descripción variables esenciales

Debido a la gran cantidad de variables que se crearon para el modelo, explicar individualmente el origen y el proceso de extracción de cada una resultaría poco práctico. Por ello, nos centraremos en detallar aquellas variables que consideramos esenciales y que requirieron un mayor nivel de procesamiento o conocimiento técnico para su cálculo.

2.2.1. Descomposición y Desagregación de Series Temporales mediante LOESS

Un problema que encontramos al extraer variables fue que varias presentaban una periodicidad anual, como el PIB por ciudad, el número de establecimientos de turismo, camas, habitaciones y todas las variables de gastos turísticos. Aunque una opción habría sido asignar el mismo valor a lo largo del año, confiando en que el modelo aprendería de esta constante, optamos por aplicar una descomposición LOESS a las series temporales.

La descomposición LOESS es una técnica de suavizamiento local que ajusta regresiones en ventanas móviles de la serie temporal, permitiendo capturar tendencias y patrones estacionales sin asumir una forma funcional global. El principal desafío de esta técnica radica en definir un patrón mensual adecuado para la descomposición. En nuestro caso, para las variables de PIB y costos de viaje, utilizamos la inflación mensual de cada año, asumiendo que el PIB se ve impulsado por la tendencia inflacionaria y que los costos guardan una relación directa con la misma. Por otro lado, para las variables de establecimientos se adoptó la tendencia mensual publicada por el Ministerio de Industria y Comercio. De esta forma, logramos resultados como los presentados en la figura 2, en donde podemos observar los establecimientos de turismo y una desagregación mensual de los costos del viaje por departamento.




Figura 2: Establecimientos de turismo por mes y costos del viaje por departamento. Elaboración Propia

2.2.2. Variables de Área

Las variables de: Área Urbana, Área Rural y Área de Agua de cada ciudad se calcularon utilizando las imágenes tomadas por el satélite Sentinel-2. Para ello, se accedió a los servidores del satélite y a la serie histórica de imágenes en las áreas de cada ciudad desde 2018 hasta 2023. Tras aplicar un filtro de nubes, se calcularon los índices de: NDVI, GNDVI, EVI, NDWI, MNDWI, NDBI y AWEIsh, los cuales permiten diferenciar entre zonas urbanas, rurales y acuáticas. Gracias al método Otsu, se determinaron umbrales óptimos para cuantificar en km² cada una de estas áreas y analizar su evolución a lo largo del tiempo. En el cuadro 1 se presentan los resultados de las áreas promedio por ciudad cabecera, mediana y pequeña.

Tipo Ciudad	Nmero Extranjeros	Área Urbana	Área Rural	Área Agua
Ciudad Pequeña	915.63	8.63	2.59	0.29
Ciudad Media	8990.02	56.23	16.08	0.77
Cabecera	74579.17	153.44	36.48	0.67

Cuadro 1: Media de las variables de área por el tipo de ciudad. Elaboración Propia

La integración de estas variables facilitó la generación de estadísticas que reflejan con precisión las distintas coberturas del suelo. Cada imagen fue procesada en lotes, garantizando la consistencia temporal y espacial en la cuantificación de las áreas, lo que permitió identificar tendencias en el crecimiento urbano y rural. Además, la validación de los resultados se realizó mediante la comparación con datos oficiales de referencia, confirmando la robustez del enfoque.

Con el análisis de la figura 3 y el cuadro 1, podemos concluir que existe una relación directa entre la cantidad de área y el número de extranjeros recibidos en cada ciudad, siendo las ciudades con mayor área urbana las que reciben más extranjeros a lo largo de los años; sin embargo, otro factor importante es que las ciudades con mayor área acuática, aunque sean pequeñas en comparación, reciben más extranjeros que sus pares.

2.2.3. Índices de Distancia

Por otro lado, las variables de distancia a los puntos de acceso se ponderaron en función de la cantidad de turistas que llegan a cada uno, fundamentándose en la idea de que resulta más relevante estar cerca del Aeropuerto El Dorado que de, por ejemplo, la frontera vial Ecuador-Colombia.




Figura 3: Evolución Variables de Área y su relación con el turismo. Elaboración Propia

Del mismo modo, la variable de distancia a los puntos turísticos se construyó considerando los 50 primeros lugares que aparecen en TripAdvisor al buscar 'Colombia' y se ponderó por el número de estrellas y de reviews de cada lugar. Finalmente, para el número de vías se utilizaron los datos de la red vial de INVIAS y se calculó la cantidad de vías principales existentes en un radio de 10 km de cada ciudad. Con estas variables obtuvimos estos resultados:




Figura 4: Scores de las variables y número de extranjeros. Elaboración Propia

En la figura 4, es fácil ver que existe una relación entre la distancia de una ciudad respecto a los accesos y lugares reconocidos y el flujo de turistas. Los departamentos más alejados son los que reciben menos turismo. Mientras tanto, ciudades como Bogotá, que cuentan con la menor distancia a lugares turísticos y a las entradas internacionales, reciben el mayor flujo de turistas del país.

2.3. Preprocesamiento de los Datos

Una vez entendidas las variables en bruto, es pertinente detallar el preprocesamiento aplicado a los datos antes de ser introducidos en el modelo. En esta etapa, el manejo de datos faltantes resultó crucial, ya que identificamos ausencias en las variables de temperatura, establecimientos de turismo y costos. En ciencia de datos, existen diversas técnicas para tratar datos faltantes, siendo una de las más valoradas la imputación mediante K-Nearest-Neighbor; sin embargo, otro método de ML, que no es tan conocido, es el Kriging. Mientras que KNN identifica a los K vecinos más cercanos basándose en similitudes

entre características, el Kriging realiza una interpolación espacial, lo que lo hace especialmente útil para variables con una relación geoespacial. Por ello, se optó por emplear Kriging en las variables de temperatura y costos, y KNN para la variable de establecimientos de turismo.

Por último se realizó un debido análisis de valores atípicos y se normalizaron los datos para que todos los modelos trabajen correctamente con los datos.

3. Modelaje y Evaluación de Despeño

Al momento de modelar, se optó por realizar un amplio ejercicio comparativo entre diversos modelos de Machine Learning, empezando desde los modelos más básicos (Regresiones Lineales Regularizadas), hasta llegar a métodos de ensamble (Random Forest), métodos de boosting (XGBoost, GradientBoosting y CatBoost) y terminar con SVM. En total se corrieron 12 modelos diferentes y, para cada uno, se hizo una búsqueda exhaustiva (grid search) de hiperparámetros, optimizando su desempeño. Con esta metodología se logró tener un amplio abanico de opciones, lo que permitió seleccionar no solo el modelo con mejores métricas de desempeño, sino también aquel que minimizara el uso de recursos computacionales. Para validar los modelos, se dividió la muestra en conjuntos de entrenamiento (70 por ciento), validación (20 por ciento) y prueba (10 por ciento), seleccionándose aquel que maximizó el coeficiente R^2 en entrenamiento y validación, con el objetivo de evitar un modelo sobreajustado a los datos de entrenamiento.

Métricas de Desempeño de los Modelos				
	R^2	MSE	MAE	RMSE
Regresión Lineal	0.7326	0.376	0.356	0.519
Regresión Lasso	0.8272	0.230	0.374	0.412
Regresión Ridge	0.7910	0.213	0.291	0.491
Elastic Net	0.9337	0.017	0.059	0.132
KNN	0.9221	0.023	0.011	0.105
Arboles de Decisión	0.9344	0.051	0.046	0.226
Random Forest	0.9518	0.029	0.021	0.143
GradientBoosting	0.9533	0.032	0.026	0.161
XGBoost	0.9816	0.037	0.015	0.122
CatBoost	0.9412	0.091	0.100	0.197
SVM	0.9001	0.162	0.141	0.212
SVM con Kernel	0.9310	0.043	0.091	0.161

Cuadro 2: Métricas de desempeño de los modelos en el conjunto de testeo.

En el cuadro 2 se pueden evidenciar las métricas de desempeño de todos los modelos que se corrieron, posteriormente a realizar la optimización de hiperparámetros. Se observa que los métodos basados en técnicas de boosting y ensemble, especialmente XGBoost, destacan por alcanzar un R^2 casi perfecto (0.9816) y errores bajos en MSE, MAE y RMSE. En contraste, modelos tradicionales como la regresión lineal presentan un rendimiento inferior, lo que respalda la ventaja de los enfoques modernos para capturar la complejidad de los datos turísticos.

Aunque modelos como SVM superan significativamente a los enfoques de regresión clásica en términos de precisión, es importante destacar que su tiempo de entrenamiento fue de aproximadamente 4 horas, lo que limita su implementación en un escenario real. En contraste, XGBoost no solo maximizó las métricas de desempeño, sino que completó su entrenamiento en menos de un minuto. Esta

combinación de alta precisión y eficiencia fue la principal razón para seleccionarlo como el modelo óptimo.

3.1. Comparación Econometrica

Aunque en la sección anterior se observó que las regresiones lineales alcanzaban desempeños muy inferiores a los modelos de Machine Learning, cabe señalar que dichas regresiones no son "puramente econométricas", ya que se emplearon variables altamente correlacionadas. Esto se traduce en coeficientes beta con mayor varianza, sesgados y con dificultades para aislar los efectos independientes de cada variable, lo que complica la interpretación precisa de sus resultados. Por ello, se desarrollaron dos regresiones que cumplen con los estándares econométricos, con el fin de contrastarlas de manera más adecuada con los modelos de ML. La primera regresión que se planea estimar aprovecha el factor del tiempo del panel, y su fórmula se presenta en la ecuación (1):

$$N_{\text{Extranjeros}_{it}} = \alpha_i + \beta_0 + \beta_1 \cdot N_{\text{Extranjeros}_{i,t-1}} + \beta_2 \cdot N_{\text{Extranjeros}_{i,t-2}} + \beta_3 \cdot \text{PIB}_{i,t-1} + \epsilon_{it} \quad (1)$$

Al estimar esta regresión se obtuvieron estos resultados:

Variable	Coefficiente	Error Est.	t-valor	p-valor
Constante	2257.5641	202.793	11.132	0.000
Nmero Extranjeros _{t-1}	-0.1539	0.032	-4.877	0.000
Nmero Extranjeros _{t-2}	0.1548	0.014	10.941	0.000
Pib Ponderado _{t-1}	0.6657	0.135	4.919	0.000
$R^2 = 0,081, \quad R^2 \text{ Ajustado} = 0,081$				

Cuadro 3: Coeficientes de la regresión

Como se ve en el Cuadro 3, aunque todos los coeficientes beta son estadísticamente significativos, tanto el R^2 como el $R^2 \text{ Ajustado}$ no superan 0.1; lo cual representa un modelo peor que el azar en términos predictivos y una reducción del 90 por ciento con respecto a XGBoost. Por ello, esta aproximación econométrica resulta en un fracaso total.

Alejándonos de los datos netamente temporales y estimando una regresión para datos panel con efectos aleatorios, la cual podemos describir con la ecuación (2):

$$N_{\text{Extranjeros}_{it}} = \beta_0 + \beta_1 \cdot \text{Homicidios}_{it} + \beta_2 \cdot \text{Gasto Promedio Viaje}_{it} + \beta_3 \cdot \text{Establecimientos de Turismo}_{it} + \beta_4 \cdot \text{Dólar}_{it} + \beta_5 \cdot \text{Temperatura}_{it} + \beta_6 \cdot \text{PIB}_{it} + \beta_7 \cdot \text{Eventos}_{it} + u_i + \epsilon_{it} \quad (2)$$

Este enfoque permite aprovechar la variabilidad tanto entre las diferentes ciudades (efectos "between") como a lo largo del tiempo (efectos "within"), lo que se traduce en estimaciones más robustas y en la reducción del sesgo por heterogeneidad. Los resultados se presentan en el cuadro 4.

Variable	Coefficiente	Error Est.	t-valor	p-valor
Constante	1861.6000	699.2300	2.6623	0.0078
Homicidios	3.6310	12.1120	0.2998	0.7644
Gasto Promedio Viaje	-0.0001	0.0007	-0.2092	0.8343
Establecimientos de turismo	10.3510	0.5159	20.0640	0.0000
Dólar	-0.6097	0.1362	-4.4764	0.0000
Temperatura	15.5170	21.1510	0.7336	0.4632
Pib Ponderado	2.4648	0.0677	36.4200	0.0000
Eventos	199.2500	54.1680	3.6784	0.0002
$R^2 \text{ (Overall)} = 0.7301, \quad R^2 \text{ (Within)} = 0.2718, \quad R^2 \text{ (Between)} = 0.8091$				

Cuadro 4: Coeficientes de la regresión Random Effects

La regresión de Efectos Aleatorios representa una mejora notable respecto al modelo previo, elevando el R^2 de 0.08 a 0.73. Este incremento en la capacidad explicativa se debe a que el enfoque de datos panel captura tanto las variaciones entre ciudades como las variaciones a lo largo del tiempo. Se observa que variables como Establecimientos de Turismo, Dólar, PIB Ponderado y Eventos resultan altamente significativas, subrayando su impacto en el flujo de turistas extranjeros. Por otro lado, la disparidad entre el R^2 "Within" (0.2718) y el "Between" (0.8091) indica que el modelo explica de manera más efectiva las diferencias estructurales entre ciudades que las fluctuaciones internas a lo largo del tiempo.

No obstante, es importante recordar que XGBoost logró un R^2 de 0.98, lo que enfatiza la clara diferencia en desempeño entre una regresión econométrica bien planteada y un enfoque de Machine Learning capaz de capturar patrones complejos con mayor eficacia.

4. Resultados de XGBoost

Una de las principales ventajas de los modelos econométricos es la facilidad para interpretarlos, lo que permite establecer relaciones causales y dependencias significativas entre las variables. En contraste, cuando se utilizan modelos avanzados de Machine Learning, la interpretación directa de los parámetros se vuelve complicada debido a la naturaleza de "caja negra" de estos métodos. Sin embargo, aunque los parámetros en sí carezcan de una interpretación directa, existen diversas técnicas que permiten identificar dependencias y relaciones entre las variables predictoras y la variable objetivo. Entre las técnicas más famosas y usadas se encuentran la imputación de características, LIME y Partial Dependence Plots (PDP).

4.1. Imputación de características

La imputación de características es una técnica que evalúa el impacto de cada variable en el desempeño del modelo. Al modificar o sustituir sistemáticamente los valores de una característica y observar los cambios en las métricas del modelo, se pueden identificar cuáles son las variables más significativas para el modelo.




Figura 5: Imputacion de Caracteristicas XGBoost. Elaboración Propia

La figura 5 revela que solo tres variables —Área Urbana, Área Rural y Área de Agua— son cruciales para el modelo, ya que su eliminación implicaría una pérdida del 12 al 37 por ciento de la capacidad para predecir la variable dependiente, siendo el Área Rural la más influyente.

Por otro lado, podemos ver que el PIB y la distancia a los accesos internacionales también resultan importantes, ya que su omisión hace que el modelo pierda entre el 9 y el 20 por ciento de su capacidad predictiva.

Por último, otros indicadores, como los establecimientos de turismo o los costos de viaje, tienen un impacto marginal, reduciendo solo alrededor del 1 por ciento.

Esta gráfica evidencia claramente que XGBoost se apoya principalmente en las variables relacionadas con las áreas, el PIB y las distancias para identificar patrones en el flujo turístico, y son estas

variables las que, según el modelo, guardan una relación más intensa con el flujo turístico de cada ciudad.

4.2. LIME

LIME (Local Interpretable Model-Agnostic Explanations) es una técnica que genera interpretaciones locales de las predicciones de modelos complejos. Se basa en aproximar el comportamiento del modelo en un vecindario alrededor de una instancia específica mediante un modelo de regresión lineal, lo que permite identificar la contribución individual de cada variable. De esta forma, LIME facilita la comprensión y validación de las decisiones del modelo, ofreciendo una visión similar a la interpretación de una regresión, pero aplicada de manera local.

Dado que en LIME se debe especificar en base a cuál registro (ciudad) se hará la interpretación, vamos a realizar dos análisis LIME: uno en una de las grandes ciudades, observando cuáles son los efectos marginales (betas) que resultan, y otro en una ciudad pequeña. El propósito de esto es identificar cuáles son las variables que más influyen el turismo en las grandes y pequeñas ciudades, o si se trata de las mismas.




Figura 6: Lime para una ciudad principal. Elaboración Propia

Según la figura 6 y utilizando LIME, se observa que, para las grandes ciudades, contar con un área mayor a 14 km² y un área rural mayor a 4 km² aumenta el número de turistas en más de 8.000, lo que deja claro que estas son las características más significativas para una ciudad grande. Además, los hurtos superiores a 155 también tienen una influencia positiva en la predicción; esto se debe a que esta variable está funcionando como un proxy del tamaño o la actividad económica, pero no establece una causalidad directa.

Asimismo, un PIB mayor a 572 billones por mes y más de 30 establecimientos de turismo aumentan el flujo de turistas entre 2.000 y 4.000, lo que refuerza la idea de que el desarrollo económico es crucial para sostener grandes flujos turísticos, evidenciando cómo factores macroeconómicos y de infraestructura se combinan para atraer visitantes.

Por otro lado, LIME permite destacar que otras características, como el área de agua, logran atraer un gran flujo de turistas. En contraste, contar con altos niveles de pobreza, altos gastos promedio del viaje, una baja relevancia de puntos de acceso internacionales (como aeropuertos o fronteras) y tener un clima frío reducen significativamente el número de turistas. Finalmente, las variables que menos destacan en las ciudades grandes son: la inflación, los delitos sexuales, el gasto en transporte y el número de vías cercanas. Una posible explicación es que, en las ciudades principales, estos factores se ven opacados por características de mayor impacto mediático y estructural, como la infraestructura turística, la actividad económica y la misma popularidad de la ciudad.




Figura 7: Lime para una ciudad promedio. Elaboración Propia

En la interpretación de LIME para una ciudad promedio, se evidencia una dinámica distinta en comparación con las grandes urbes. En este contexto, el tamaño del área urbana, rural y de agua, especialmente cuando se sitúa entre 0.98 y 14.16 km², es el factor que más contribuye negativamente a la predicción del número de turistas, lo que indica que las ciudades con áreas más reducidas tienen una capacidad limitada para atraer flujos turísticos significativos. Sumado a esto, variables como un PIB bajo, grandes distancias a los principales puntos de acceso internacionales y el precio del dólar reducen aún más la capacidad de la ciudad para atraer turistas.

Sin embargo, la cantidad de eventos en la ciudad emerge como el principal impulsor positivo, subrayando que en estas ciudades las actividades culturales y recreativas pueden compensar, en parte, la carencia de una infraestructura de gran escala. También se puede ver que unos costos de viaje reducidos potencian de gran manera el flujo de turistas; aunque, entre estos, los costos de transporte son los más importantes, lo que indica que los turistas prefieren viajar a ciudades donde les es más barato llegar.

Por último, se puede ver que todas las variables de infraestructura aportan negativamente; esto refuerza la importancia de invertir en infraestructura turística local. En conclusión, en grandes ciudades como Bogotá, el tamaño del área urbana es el principal determinante del turismo, apoyado por una robusta oferta de infraestructura y servicios; en cambio, en las ciudades de menor escala, la realización de eventos atractivos se presenta como la estrategia clave para contrarrestar las limitaciones inherentes

a un área urbana reducida.

4.3. Partial Dependence Plots

Las Partial Dependence Plots son gráficos interpretativos que muestran el efecto marginal de una variable sobre la predicción del modelo. Estos gráficos permiten visualizar de manera clara cómo varían las predicciones al modificar el valor de una característica, ayudando a identificar patrones no lineales y relaciones de interacción.




Figura 8: PDP para las variables independientes. Elaboración Propia

En la figura 8 se presentan las Partial Dependence Plots (PDP) para nueve variables que, a lo largo de la investigación, se han identificado como las más influyentes en la predicción del flujo turístico. En la primera fila se evidencia que el flujo de turistas tiene un crecimiento exponencial cuando el área urbana supera los 20 km² y el área rural supera los 60 km², incrementándose la cantidad de turistas esperados en un rango de 30 a 40 mil. En complemento, el PIB presenta un aumento de 12 mil turistas cuando se superan los 4041 millones de pesos.

En la segunda fila, se destaca que las temperaturas extremas (muy frías o altas) reducen el potencial turístico, siendo el rango óptimo entre 17 y 25 °C. Sin embargo, el efecto positivo de aumentar el número de establecimientos de turismo y la realización de eventos culturales es notable y termina de validar los resultados de LIME, ya que contar con más de 600 establecimientos incrementa el flujo en aproximadamente 7 mil turistas, y la celebración de más de tres eventos aporta un aumento de 2800 turistas.

Por último, la tercera fila enfatiza que tanto una mayor distancia a los puntos de interés más reconocidos como unos costos turísticos elevados en la ciudad tienen efectos negativos, mientras que disponer de un mayor número de vías principales de acceso favorece la llegada de turistas extranjeros. Estos resultados subrayan la importancia de la infraestructura, la actividad cultural y la accesibilidad para impulsar el turismo en las diferentes ciudades.

5. Conclusiones

A lo largo de la investigación, hemos evidenciado que los métodos de Machine Learning ofrecen ventajas significativas sobre los enfoques econométricos tradicionales en la predicción de fenómenos complejos, como el turismo. Mientras que en las regresiones econométricas se debe estipular una forma funcional clara para las variables y cumplir con diversos supuestos —por ejemplo, la linealidad de los parámetros y la ausencia de multicolinealidad—, los modelos de ML, como XGBoost, capturan relaciones no lineales y patrones complejos sin estar limitados a una representación en forma de ecuación, lo que les permite lograr precisiones predictivas excepcionales.

Por otro lado, la investigación evidencia que el turismo en Colombia se ve determinado por una compleja interacción de factores, cuyos efectos varían según el tamaño y las características de cada ciudad. En grandes urbes como Bogotá, un área urbana extensa (mayor a 70 km²) y un PIB elevado (superior a 9000 mil millones anuales) se consolidan como los principales impulsores del flujo turístico; estas dos variables no son más que un complemento de una robusta infraestructura y una amplia oferta de servicios. No obstante, estos beneficios se ven contrarrestados por barreras como altos costos de viaje, elevados gastos en alimentación, deficiencias en la conectividad internacional y altas tasas de crímenes y pobreza, que limitan el potencial turístico pese a las ventajas estructurales.

En contraste, en ciudades pequeñas y promedio, donde las limitaciones de infraestructura y tamaño son evidentes, los eventos locales y el crecimiento en el número de establecimientos turísticos emergen como estrategias clave para estimular el turismo. Concretamente, la realización de más de dos eventos culturales y el superar umbrales críticos en el número de establecimientos permite compensar la falta de área construida, mientras que la conectividad mediante vías principales y la proximidad a puntos de interés facilitan la llegada de visitantes. Factores transversales como la diversidad territorial, las condiciones climáticas moderadas y la seguridad también juegan un papel crucial en la atracción turística.

Por último, es fundamental implementar estrategias diferenciadas que potencien las fortalezas de cada región. En las grandes ciudades se debe mejorar la conectividad internacional y reducir las barreras de costos, mientras que en las ciudades más pequeñas es prioritario promover eventos culturales y desarrollar la infraestructura turística local. Los análisis de LIME y las Partial Dependence Plots revelan que, en las urbes de mayor escala, ampliar el área urbana y optimizar la infraestructura de transporte, así como mejorar la percepción de seguridad general, contribuyen significativamente a incrementar el flujo de turistas; por ello, se recomienda invertir en la modernización de los servicios de movilidad, en proyectos de infraestructura urbana correctamente planificada y en programas de justicia y seguridad.

En contraste, para las ciudades pequeñas, donde la limitación de espacio es un desafío, la realización de eventos culturales y el fomento de la identidad local emergen como estrategias clave para compensar la menor infraestructura, de modo que el impulso de festivales, ferias y actividades recreativas, junto con alianzas estratégicas con operadores turísticos locales, puede transformar estas limitaciones en ventajas competitivas y atraer a un público extranjero diverso.